

机器学习与数据科学

Machine Learning and Data Science

主讲: 李春光

www.pris.net.cn/teacher/lichunguang

模式识别与智能系统实验室

信息与通信工程学院 网络搜索教研中心

北京邮电大学




专题二：线性模型

数学基础知识补充-I

- 内容提要
 - 凸集分离定理
 - 无约束优化问题

凸集分离定理

- 如果两个凸集分离，则可以用一张超平面将两者隔在两边
 - 也被称为超平面分离定理 (**Separating Hyperplane Theorem**)
 - 直观地看，凸集分离是指两个凸集没有交叉和重合的部分




- 应用:
 - **Farkas**引理——最优性条件中最重要的基础
 - 基于**Farkas**引理，可以证明**Gordan**定理
 - Gorden定理在证明最优性条件(Kuhn-Tucker条件)起关键作用

线性可分性的等价条件

- 线性可分等价于两个凸集可分
 - 借助**Farkas**定理可以检测是否线性可分

Farkas 定理: 不等式方程组
$$\begin{cases} A\mathbf{w} < 0 \\ \mathbf{c}^T \mathbf{w} > 0 \end{cases}$$

有解的充要条件是方程
$$\begin{cases} A^T \mathbf{y} = \mathbf{c} \\ \mathbf{y} \geq 0 \end{cases}$$
 无解.




Gordan定理

- Gordan定理

设 A 为 $m \times n$ 矩阵, 那么 $A\mathbf{x} < 0$ 有解的充要条件是:
不存在非零向量 $\mathbf{y} \geq 0$, 使得 $A^T \mathbf{y} = 0$

- 原不等式组无解 \rightarrow 另一组不等式组有解
 - 可用于建立最优性条件的代数表示



梯度与下降方向

- 梯度

- 梯度：增长最快的方向
- 方向导数：梯度与方向的内积

- 下降方向

设 $f : R^n \mapsto R$ 在点 $\bar{x} \in R^n$ 处可微。若存在 $p \in R^n$ ，使 $\nabla f(\bar{x})^T p < 0$ ，则向量 p 是 $f(x)$ 在点 \bar{x} 处的下降方向

- 最速下降方向

- 最快下降方向：梯度的反方向

有约束优化问题的最优性条件

- 几何条件：

- 可行方向的集合与下降方向的集合相交为空集

- 在局部最优点处，算法在寻找下降方向时发现已无路可走，即算法无法从可行集中找到下降方向
 - \mathbf{x}^* 是一个最优点，当且仅当它是一个可行点且对于所有可行向量 \mathbf{u} 如下条件成立：

$$\nabla f(\mathbf{x}^*)^T (\mathbf{u} - \mathbf{x}^*) \geq 0$$

- 为了在计算中检验最优性条件，需要建立最优性条件的代数表示

- **KKT 条件**

- Lagrangian函数关于原变量的一阶条件
 - 原变量的可行条件
 - 对偶变量的可行条件
 - 针对不等式约束的互补松弛条件

有约束最优化问题 举例

- 无约束最优化问题: $\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x})$
 - 由于 $\mathbf{u} - \mathbf{x}^*$ 是任意向量, 因此得到: $\nabla f(\mathbf{x}^*)^T = 0$
- 线性等式约束最优化问题: $\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) \text{ s.t. } A\mathbf{x} = \mathbf{b}$
 - 设 \mathbf{x}^* 是可行解(i.e. $A\mathbf{x}^* = \mathbf{b}$) 且存在对偶证书(dual certificate)向量 \mathbf{v} 满足:
$$A\mathbf{x}^* = \mathbf{b}, \quad \nabla f(\mathbf{x}^*) + A^T \mathbf{v} = 0$$
- 非负约束最优化问题: $\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) \text{ s.t. } \mathbf{x} \geq \mathbf{0}$
 - 令 $\mathbf{u} = 2\mathbf{x}^*$, $\mathbf{u} = \mathbf{0}$, 则得出最优性条件
$$\nabla f(\mathbf{x}^*)^T \mathbf{x}^* = 0, \quad \nabla f(\mathbf{x}^*) \geq 0, \quad \mathbf{x}^* \geq 0$$

专题二：线性模型

数学基础知识补充


- 内容提要
 - 凸集分离定理
 - 无约束优化问题

无约束最优化问题

- 问题定义



$$\min_{\mathbf{x}} f(\mathbf{x})$$

其中 $\mathbf{x} = (x_1, x_2, \dots, x_n)^T \in R^n$, $f : R^n \rightarrow R$



迭代下降算法基本思想

- 迭代下降算法：
 - 寻找一个搜索方向 $\mathbf{d}^{(k)}$ ，使得每次迭代时函数值减小，即 $\mathbf{x}^{(k+1)} \leftarrow \mathbf{x}^{(k)} + \mathbf{d}^{(k)}$ ，有 $f(\mathbf{x}^{(k+1)}) \leq f(\mathbf{x}^{(k)})$



迭代下降算法基本步骤

第 1 步

选取初始点 $x^{(0)}$, $k:=0$;

第 2 步

构造搜索方向 $d^{(k)}$;


第 3 步

根据 $d^{(k)}$, 确定步长 λ_k ;

第 4 步

令 $x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$,

若 $x^{(k+1)}$ 已满足某种终止条件, 停止迭代, 输出近似解 $x^{(k+1)}$; 否则令 $k:=k+1$, 转回第 2 步。



— 初始点、搜索方向和步长参数

最速下降法

要求：目标函数 $f(x)$ 一阶连续可微

- 由柯西 (Cauchy) 在1847年提出的，是求无约束极值的最早的数值算法

步骤：

第 1 步 选取初始点 $x^{(0)}$ ，给定终止误差 $\varepsilon > 0$ ，令 $k := 0$ ；

第 2 步 计算 $\nabla f(x^{(k)})$ ，若 $\|\nabla f(x^{(k)})\| < \varepsilon$ ，停止迭代，输出 $x^{(k)}$ 。

否则进行第 3 步；

第 3 步 取 $d^{(k)} = -\nabla f(x^{(k)})$

第 4 步 进行一维搜索，求 λ_k ，使得

$$f(x^{(k)} + \lambda_k d^{(k)}) = \min_{\lambda \geq 0} f(x^{(k)} + \lambda d^{(k)})$$

令 $x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$ ， $k := k + 1$ ，转第 2 步。

典型的无约束优化算法

- 根据搜索方向的不同，分为：

- 最速下降法

- 牛顿法

- 阻尼牛顿法

- 修正牛顿法

- 伪(Pseudo)牛顿法

- 共轭梯度法

- 最小二乘法

- 线性最小二乘

- 非线性最小二乘

- 修正最小二乘法