

机器学习与数据科学

Machine Learning and Data Science

主讲: 李春光

www.pris.net.cn/teacher/lichunguang

模式识别与智能系统实验室

信息与通信工程学院 网络搜索教研中心

北京邮电大学



专题二：线性模型

数学基础知识补充-II

- 内容提要

- 矩阵分析基础

- 迹
 - 范数
 - 矩阵的实值函数求微分

- 凸(**convex**)优化

- 凸集(convex set)
 - 凸函数(convex function)

矩阵的迹(Trace)

- 对于一个 $m \times m$ 方阵 A ，它的迹等于其对角线元素的和：

$$\text{trace}(A) = \sum_{i=1}^m a_{ii}$$

- 一个 $m \times n$ 的矩阵 A 的 Frobenius 范数(Norm):

$$\|A\|_F^2 = \sum_{i=1}^m \sum_{j=1}^n a_{ij}^2$$

- 矩阵 A 的 Frobenius 范数与迹的关系:

$$\|A\|_F^2 = \text{trace}(A^T A) = \text{trace}(AA^T)$$

- 矩阵迹的运算性质:

$$\begin{aligned} \text{trace}(AB) &= \text{trace}(BA), & \text{trace}(A) &= \text{trace}(A^T) \\ \text{trace}(ABC) &= \text{trace}(CAB) = \text{trace}(BCA) \end{aligned}$$

矩阵的实值函数求导数

- 考虑矩阵 X 的实值函数

$$\nabla f(X) = \nabla \text{trace}(X^T A) = A$$

$$\nabla f(X) = \nabla \text{trace}(AX) = A^T$$

$$\nabla f(X) = \nabla \text{trace}(X^T AX) = AX + A^T X$$

$$\nabla \|X\|_F^2 = \nabla \text{trace}(X^T X) = 2X$$

参考资料

- 线性代数回顾
 - http://www.deeplearningbook.org/contents/linear_algebra.html
- 迹的性质和矩阵的微分：
 - http://web.stanford.edu/~jduchi/projects/matrix_prop.pdf

专题二：线性模型

数学基础知识补充-II

- 内容提要

- 矩阵分析基础

- 迹
 - 范数
 - 矩阵的实值函数求微分

- 凸(**convex**)优化

- 凸集(convex set)
 - 凸函数(convex function)

凸集和凸函数

- 凸集:
 - 给定集合**S**，对于**S**中的两个元素 x_1 和 x_2 ，如果对于任意 $0 \leq \alpha \leq 1$ ，有： $\alpha x_1 + (1 - \alpha) x_2 \in S$ 则称**S**为凸集
- 凸函数
 - 在最优化中，即**convex** 函数，指下凸函数
 - 函数 $f(x)$ ，对于任意 $0 \leq \alpha \leq 1$ ，有：
$$f(\alpha x_1 + (1 - \alpha) x_2) \leq \alpha f(x_1) + (1 - \alpha) f(x_2)$$
 - 称之为凸函数(convex function)

凸(convex)优化

- 对于一个最优化问题，如果目标函数为凸函数，可行集为凸集，即为凸优化问题
 - 等式约束为只能为线性约束
 - 不等式约束的可行集为凸集
- 判定条件：
 - 一阶条件
$$f(\mathbf{x}_2) \geq f(\mathbf{x}_1) + \nabla f(\mathbf{x}_1)^T (\mathbf{x}_2 - \mathbf{x}_1)$$
 - 二阶条件
 - 假设函数2阶可微. 在每一点处，Hessian矩阵为半正定
- 局部极小值点即为全局极小值点