

机器学习与数据科学

Machine Learning and Data Science

主讲: 李春光

www.pris.net.cn/teacher/lichunguang

模式识别与智能系统实验室

信息与通信工程学院 网络搜索教研中心

北京邮电大学



专题 六：支持向量机与统计学习理论

数学基础知识补充-I

- 内容提要

- 有约束最优化问题的最优性条件
- Lagrange对偶问题
 - 弱对偶定理
 - 强对偶定理
 - 鞍点定理

有约束优化问题的最优性条件

- 几何条件：
 - 可行方向的集合与下降方向的集合相交为空集
 - 在局部最优点处，算法在寻找下降方向时发现已无路可走，即算法无法从可行集中找到下降方向

- \mathbf{x}^* 是一个最优点，当且仅当它是一个可行点且对于所有可行向量 \mathbf{u} 如下条件成立：

$$\nabla f(\mathbf{x}^*)^T (\mathbf{u} - \mathbf{x}^*) \geq 0$$

有约束最优化问题最优性条件举例

- 无约束最优化问题: $\min_{\mathbf{x} \in R^n} f(\mathbf{x})$
 - 由于 $\mathbf{u} - \mathbf{x}^*$ 是任意向量, 因此得到: $\nabla f(\mathbf{x}^*)^T = 0$
- 线性等式约束最优化问题: $\min_{\mathbf{x} \in R^n} f(\mathbf{x}) \text{ s.t. } A\mathbf{x} = \mathbf{b}$
 - 设 \mathbf{x}^* 是可行解(i.e. $A\mathbf{x}^* = \mathbf{b}$) 且存在对偶证书(dual certificate)向量 \mathbf{v} 满足:
$$A\mathbf{x}^* = \mathbf{b}, \quad \nabla f(\mathbf{x}^*) + A^T \mathbf{v} = 0$$
- 非负约束最优化问题: $\min_{\mathbf{x} \in R^n} f(\mathbf{x}) \text{ s.t. } \mathbf{x} \geq \mathbf{0}$
 - 令 $\mathbf{u} = 2\mathbf{x}^*$, $\mathbf{u} = \mathbf{0}$, 则得出最优性条件
$$\nabla f(\mathbf{x}^*)^T \mathbf{x}^* = 0, \quad \nabla f(\mathbf{x}^*) \geq 0, \quad \mathbf{x}^* \geq 0$$

KKT最优性条件

- 为了在计算中检验最优性条件，需要建立最优性条件的代数表示：
 1. Lagrangian函数关于原变量的一阶条件
 2. 原变量的可行条件
 3. 对偶变量的可行条件
 4. 针对不等式约束的互补松弛条件
 - 不等式约束取等号与对偶变量取等号之间的“互补”

求解线性支持向量机问题的KKT条件

- 原问题:

$$\min_{\mathbf{w}, b} \frac{1}{2} \mathbf{w}^T \mathbf{w}, \quad \text{s.t.} \quad (\mathbf{w}^T \mathbf{x}_i + b) y_i \geq 1, \quad i = 1, \dots, N.$$

- Lagrange函数

$$L(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i (y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1), \quad \text{where } \alpha_i \geq 0, \quad i = 1, \dots, N.$$

- KKT 条件是1阶必要条件:

$$\begin{cases} \nabla_{\mathbf{w}} L(\mathbf{w}, b, \alpha) = 0, \quad \nabla_b L(\mathbf{w}, b, \alpha) = 0 \\ y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1 \geq 0, \quad i = 1, \dots, N \\ \alpha_i \geq 0, \quad i = 1, \dots, N \\ \alpha_i [y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1] = 0, \quad i = 1, \dots, N \end{cases}$$



$$\begin{cases} \mathbf{w} = \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i, \\ \sum_{i=1}^N \alpha_i y_i = 0. \end{cases}$$

求解线性支持向量机问题的KKT条件

- 原问题:

$$\min_{\mathbf{w}, b} \frac{1}{2} \mathbf{w}^T \mathbf{w}, \quad \text{s.t. } (\mathbf{w}^T \mathbf{x}_i + b) y_i \geq 1, \quad i = 1, \dots, N.$$

- Lagrange函数

$$L(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i (y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1), \quad \text{where } \alpha_i \geq 0, \quad i = 1, \dots, N.$$

- KKT 条件是1阶必要条件:

$$\begin{cases} \nabla_{\mathbf{w}} L(\mathbf{w}, b, \alpha) = 0, & \nabla_b L(\mathbf{w}, b, \alpha) = 0 \\ y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1 \geq 0, & i = 1, \dots, N \\ \alpha_i \geq 0, & i = 1, \dots, N \\ \alpha_i [y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1] = 0, & i = 1, \dots, N \end{cases}$$

求解线性支持向量机问题的KKT条件

- 原问题:

$$\min_{\mathbf{w}, b} \frac{1}{2} \mathbf{w}^T \mathbf{w}, \quad \text{s.t. } (\mathbf{w}^T \mathbf{x}_i + b) y_i \geq 1, \quad i = 1, \dots, N.$$

- Lagrange函数

$$L(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i (y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1), \quad \text{where } \alpha_i \geq 0, \quad i = 1, \dots, N.$$

- KKT 条件是1阶必要条件:

$$\begin{cases} \nabla_{\mathbf{w}} L(\mathbf{w}, b, \alpha) = 0, & \nabla_b L(\mathbf{w}, b, \alpha) = 0 \\ y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1 \geq 0, & i = 1, \dots, N \\ \alpha_i \geq 0, & i = 1, \dots, N \\ \alpha_i [y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1] = 0, & i = 1, \dots, N \end{cases}$$

专题 六：支持向量机与统计学习理论

数学基础知识补充-I

- 内容提要

- 有约束最优化问题的最优性条件
- **Lagrange**对偶问题
 - 弱对偶定理
 - 强对偶定理
 - 鞍点定理

考虑线性支持向量机问题

- 原问题:

$$\min_{\mathbf{w}, b} \frac{1}{2} \mathbf{w}^T \mathbf{w}, \quad \text{s.t. } (\mathbf{w}^T \mathbf{x}_i + b) y_i \geq 1, \quad i = 1, \dots, N.$$

- Lagrange函数

$$L(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i (y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1), \quad \text{where } \alpha_i \geq 0, \quad i = 1, \dots, N.$$

原问题 vs. 对偶问题

- **原问题** $\min_{\mathbf{w}, b} P(\mathbf{w}, b) \quad \text{s.t.} \quad (\mathbf{w}, b) \in \Omega$

其中 $P(\mathbf{w}, b) = \frac{1}{2} \mathbf{w}^T \mathbf{w}$

$$\Omega = \left\{ (\mathbf{w}, b) \mid y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1, \forall i = 1, \dots, N \right\}$$

- **对偶函数与对偶问题**

$$\max_{\alpha} D(\alpha) \quad \text{s.t.} \quad \alpha_i \geq 0, \quad i = 1, \dots, N$$

其中 $D(\alpha) = \min_{\mathbf{w}, b} L(\mathbf{w}, b, \alpha)$

– 两者有何联系？



弱对偶理论


- 弱对偶理论

- 设 \mathbf{w} 和 \mathbf{b} 为原问题的可行解， α 为对偶问题的可行解， 则有 $D(\alpha) \leq P(\mathbf{w}, \mathbf{b})$

- 证明: (略)

- 推论:

- 如果 $(\mathbf{w}_0, \mathbf{b}_0)$ 为原问题的可行解， α_0 为对偶问题的可行解， 且 $D(\alpha_0) \geq P(\mathbf{w}_0, \mathbf{b}_0)$ ， 则 $(\mathbf{w}_0, \mathbf{b}_0)$ 和 α_0 为分别为原问题和对偶问题的最优解
 - 如果原问题极小值为负无穷， 则对偶函数为负无穷； 如果对偶函数极大值为正无穷， 则原问题没有可行解



在实际求解最优化问题中有何应用价值?

对偶间隙(dual gap)

- 根据弱对偶理论，如果原问题的目标函数最优值为 p , 对偶问题的目标函数最优值为 q , 则必有

$$q \leq p$$

- 如果严格不等号成立，则存在对偶间隙

$$\delta = p - q > 0$$

强对偶理论

- 强对偶理论

- 对于凸(**convex**)优化问题，在适当的约束规格(**Constraint Qualification**)下，则有

$$q = p$$

其中 $q = \max_{\alpha \geq 0} D(\alpha) = \max_{\alpha \geq 0} \min_{\mathbf{w}, b} L(\mathbf{w}, b, \alpha),$

$$p = \min_{(\mathbf{w}, b) \in \Omega} P(\mathbf{w}, b)$$

- 即 对偶问题的最大值对应于原问题的最小值



鞍点最优性条件

- 鞍点(saddle point)

设 $L(\mathbf{w}, b, \alpha)$ 为Lagrange函数, 如果对于每个 (\mathbf{w}, b) 和 $\alpha \geq 0$, 有

$$L(\bar{\mathbf{w}}, \bar{b}, \alpha) \leq L(\bar{\mathbf{w}}, \bar{b}, \bar{\alpha}) \leq L(\mathbf{w}, b, \bar{\alpha})$$

则称 $(\bar{\mathbf{w}}, \bar{b}, \bar{\alpha})$ 为 $L(\mathbf{w}, b, \alpha)$ 的鞍点



- 鞍点定理

1. 鞍点对应最优点
2. 对于凸优化问题, 在CQ条件下, 最优点对应于一个鞍点

在实际求解最优化问题中有何应用价值?